



Analisi Predittiva del Prezzo di Diamanti

1. Scenario e Task: Perché la Regressione?

L'obiettivo del progetto è quello di prevedere il prezzo di diamanti basandosi sulle loro caratteristiche gemmologiche:

- Peso in carati (Carat Weight)
- Qualità del taglio (Cut)
- Colore (Color)
- Lucidatura (Polish)
- Simmetria (Symmetry)
- Ente di gradazione (Report)

Tutte queste caratteristiche farebbero pensare ad una task di classificazione, tuttavia la variabile target è il prezzo (Price), una variabile numerica continua, quindi la task che andremo ad affrontare sarà uno di Regressione. Il modello non deve solo etichettare un diamante come "costoso", ma calcolarne il valore esatto su una scala monetaria, rendendo necessario un approccio matematico.

Prenderemo come riferimento un data-set esistente con tanto di prezzi, così da poter ottenere predizioni accurate basate su dati storici reali, si tratterà quindi di un Apprendimento Supervisionato.

2. Il data-set utilizzato e le sue caratteristiche.

Il data-set di riferimento (diamond.csv) è stato preso dai beginner-level data-set messi a disposizione dagli utenti di Kaggle.com (link per riferimento <https://www.kaggle.com/datasets/ahmettezcantekin/beginner-datasets>).

Come specificato nel punto 1, tiene conto delle varie caratteristiche gemmologiche di diamanti, raccolti da laboratori di qualificati per elargire certificati di autenticità.

Il dataset è composto da 6.000 osservazioni e 8 variabili. Rappresenta un campione eterogeneo di diamanti certificati, con prezzi che variano da poche centinaia a decine di migliaia di dollari.

Variabili numeriche:

- Carat Weight (Peso in Carati): È la variabile più influente. Il carato misura il peso del diamante (1 carato = 0,2 grammi). Nel data-set, i prezzi tendono a crescere in modo esponenziale rispetto al peso, poiché i diamanti grandi sono molto più rari.
- Price (Target): Il valore in dollari. La distribuzione dei prezzi è tipicamente positivamente asimmetrica (*right-skewed*): ci sono molti diamanti economici e pochi diamanti di estremo lusso.

Variabili Categoricali

Queste variabili seguono una scala di valore precisa che il modello deve imparare:

- Cut (Taglio): Indica la qualità della lavorazione. La scala nel dataset include: Fair, Good, Very Good, Ideal e Signature-Ideal. Un taglio migliore aumenta drasticamente la brillantezza.



Analisi Predittiva del Prezzo di Diamanti

- **Color (Colore):** Basato sulla scala della Gemological Institute of America (GIA); i diamanti sono valutati per la loro trasparenza. La scala va da J (leggermente giallognolo) a D (totalmente incolore e più prezioso).
- **Clarity (Purezza):** Misura la presenza di imperfezioni interne o esterne. Va da I1 (included to 1st degree/incisioni visibili a occhio nudo) a IF o FL (internally flawless/flawless).
- **Polish (Lucidatura) e Symmetry (Simmetria):** Indicano la cura nei dettagli finali della pietra. Anche se hanno gradi come EX (Excellent) o VG (Very Good), spesso vengono trattate come caratteristiche nominali per catturare sfumature specifiche.
- **Report (Laboratorio di certificazione):** Indica quale ente ha emesso il certificato (es. GIA o AGSL). Questo è un fattore di fiducia: un certificato GIA può influenzare la percezione del valore rispetto ad altri laboratori.

3. Le issue analizzate, le soluzioni proposte e le scelte di progettazione effettuate

La scelta del Random Forest Regressor è dettata dalla natura specifica del mercato dei diamanti:

1. **Non-Linearità:** Il prezzo dei diamanti non cresce in modo lineare. Un diamante da 2 carati può costare molto più del doppio di uno da 1 carato a causa della rarità. Gli alberi di decisione catturano queste relazioni esponenziali e i "salti di prezzo" meglio della regressione lineare.
2. **Robustezza:** Essendo un modello *ensemble* (una foresta di 100 alberi), è meno sensibile agli outlier e ai diamanti rarissimi che potrebbero distorcere la media delle predizioni.

Gestione dei missing values

Prima di procedere all'encoding, è stata effettuata un'ispezione del data-set per identificare celle vuote o valori incoerenti (es. carati pari a zero).

Sebbene il data-set specifico non presentasse un numero critico di *missing-values*, abbiamo impostato il codice in modo che sia *fault-tolerant*. Nello script, il caricamento dei dati è protetto da un blocco `try-except`, assicurando che il flusso si interrompa con un messaggio d'errore chiaro in caso di problemi di integrità del file.

Gestione della Semantica delle Categorie (Encoding)

Il data-set contiene variabili categoriche con logiche profondamente diverse. Trattare tutte allo stesso modo avrebbe portato a una perdita di informazioni o a errori interpretativi del modello, di conseguenza modelliamo il nostro approccio sulla base delle caratteristiche delle variabili in oggetto.

Quando parliamo di variabili ordinali (Cut, Color e Clarity), queste variabili seguono una gerarchia precisa dettata dagli standard internazionali (un diamante D (color) è superiore a un J), quindi andremo a implementare un `OrdinalEncoder`; definendo manualmente le liste di priorità (`cut_order`, `color_order`, ecc.). Questo permette al modello di mappare la qualità su una scala numerica crescente, preservando la relazione d'ordine.

Per le variabili nominali (Report, Polish, Symmetry) non esiste una gerarchia numerica unica, di conseguenza applicheremo `One-Hot-Encoding`, riducendo le variabili a semplici vettori booleani per indicare la presenza o assenza in una colonna binaria indipendente.



Analisi Predittiva del Prezzo di Diamanti

Gestione della Non-Linearità e degli Outlier

Il prezzo dei diamanti non segue una crescita lineare rispetto al peso (Carat Weight). Le crescite tendono ad essere esponenziali per le pietre rare.

Per gestire questa caratteristica è stato scelto Random Forest Regressor. Essendo un modello basato su ensemble di alberi di decisione, è naturalmente capace di catturare relazioni non lineari attraverso split ricorsivi. Inoltre, la natura stocastica del modello lo rende meno sensibile agli outlier estremi rispetto a una regressione lineare classica.

Per gestire la natura esponenziale dei prezzi, abbiamo utilizzato una trasformazione logaritmica del target, così da ridurre l'impatto della varianza all'interno del data-set; Il motivo è semplice: nel mercato dei diamanti, un errore di 100\$ su una pietra da 500\$ è enorme (20%), mentre lo stesso errore su una pietra da 15.000\$ è irrilevante.

Prevenzione del Data Leakage

Una issue critica nei progetti di ML è l'involontario passaggio di informazioni (Data Leakage) dal set di test al set di training durante il preprocessing (split 80/20 del data-set, con una parte dedicata all'apprendimento e l'altra al testing). Per evitare questa eventualità, il flusso di lavoro è stato incapsulato in una sklearn.pipeline.

4. Analisi delle Prestazioni

La valutazione si basa su tre pilastri:

Metrica	Significato Tecnico	
R² Score	Coefficiente di determinazione	Indica la percentuale di varianza spiegata (es. 0.96 = 96% di precisione globale).
MAE	Mean Absolute Error	L'errore medio in dollari. Indica quanto "dista" mediamente la predizione dal prezzo reale.
RMSE	Root Mean Squared Error	Penalizza gli errori grandi. Fondamentale per vedere se sbagliamo grossolanamente sui diamanti di lusso

Spiegazione dei Grafici Generati

- **Distribuzione dei Prezzi (Histplot):** Visualizza come sono distribuiti i prezzi nel dataset, evidenziando se ci sono più pietre economiche o di lusso.
- **Real vs Predicted (Scatterplot):** È la prova del nove. Vedere i punti allineati lungo la diagonale a 45° conferma che il modello sta seguendo correttamente l'andamento del mercato.
- **Analisi dei Residui:** Mostra la distanza tra prezzo reale e predetto. Una distribuzione casuale intorno alla linea dello zero indica un modello sano; schemi a "imbuto" suggerirebbero la necessità di trasformazioni logaritmiche.
- **Feature Importance:** Quantifica l'impatto di ogni variabile. Questo grafico conferma che, sebbene il peso domini, il colore e la purezza agiscono come moltiplicatori decisivi.



Analisi Predittiva del Prezzo di Diamanti

5. Considerazioni Finali

In sintesi, l'architettura del modello ha mostrato un'elevata robustezza, frutto di scelte progettuali accurate che hanno consentito di valorizzare al meglio le informazioni contenute nel dataset. L'adozione di una pipeline ha assicurato controllo del flusso dei dati, riducendo il rischio di errori e garantendo l'applicazione delle trasformazioni sulle variabili categoriche.

La decisione di impiegare il Random Forest Regressor si è rivelata particolarmente efficace; la sua capacità di modellare relazioni non lineari ha permesso di descrivere con precisione il rapporto tra peso in carati e prezzo finale.

Le metriche ottenute, attestano un'ottima performance predittiva, soprattutto nella fascia di mercato più rappresentata, dove il modello raggiunge livelli di accuratezza notevoli.

L'analisi dei residui evidenzia un incremento della varianza per i diamanti di fascia altissima, un comportamento prevedibile nel contesto dei beni di lusso e scarsità. Ciò non compromette però la stabilità generale del sistema, che rimane solida.

Nel complesso, il lavoro ha portato allo sviluppo di un modello decisionale affidabile e capace di convertire dati grezzi in stime di mercato accurate.